Лабораторная работа: Bayesian Networks на примере датасета Mushroom Classification

Люзина Мария
М8О-307Б-23
26.11.25
Машинное обучение

Введение

Байесовская сеть (Bayesian Networks) – это вероятностная графическая модель, которая представляет: переменные как узлы, прямые зависимости как стрелки; хранит в каждом узле условные вероятности P(узел|его родители).

Байесовские сети нужны, когда: важна интерпретируемость, данных мало, есть причинно-следственные связи.

Например, Байесовские сети применяются в диагностике болезней в медицине:

Узлы:

- Курение → Рак лёгких
- Курение → Бронхит
- Рак лёгких → Положительный рентген
- Рак лёгких → Одышка
- Туберкулёз → Положительный рентген
- Посещение Азии → Туберкулёз

Пациент приходит с одышкой и положительным рентгеном. Врач вводит эти два факта → сеть мгновенно пересчитывает:

P(рак лёгких | одышка + положительный рентген) = 0.92

P(туберкулёз | …) = 0.05

И выдаёт не только диагноз, но и объяснение, какие симптомы на что влияют.

Датасет: Mushroom Classification

Цель – определить, съедобный ли гриб или ядовитый. Всего в датасете 8124 объекта, 22 категориальных признаков и 1 целевая переменная. В датасете нет пропусков, что упрощает подготовку данных. Этот датасет сбалансирован: ≈ 51.8 % съедобных, 48.2 % ядовитых грибов.

Признаки описывают морфологию гриба: форма и цвет шляпки, ножки, жабр, кольца, цвет спор, тип вуали, место обитания и т.д.

Несмотря на большое количество признаков, существует простое биологически осмысленное правило классификации, которое человек сразу не видит, а алгоритмы поиска структуры байесовских сетей находят автоматически.

Mushrooms – классический бенчмарк для демонстрации силы и интерпретируемости байесовских сетей.

Загрузка и обработка датасета

Загрузка датасета:

```
path = 'mushrooms.csv'
df = pd.read_csv(path)
df.head(3)
```

	class	cap-shape	cap-surface	cap-color	bruises	odor	gill-attachment	gill-spacing	gill-size	gill-color	…	stalk-surface-below-ring	stalk-color-above-ring	stalk-color-below-ring	veil-type	veil-color	ring-number	ring-type	spore-print-color	population	habitat
0	p	x	s	n	t	p	f	c	n	k	…	s	w	w	p	w	o	p	k	s	u
1	e	x	s	y	t	a	f	c	b	k	…	s	w	w	p	w	o	p	n	n	g
2	e	b	s	w	t	l	f	c	b	n	…	s	w	w	p	w	o	p	n	n	m

3 rows × 23 columns

Размер датасета и информация про него:

```
print('Размер датасета: ',df.shape)
df.info()
```

```
Размер датасета:  (8124, 23)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8124 entries, 0 to 8123
Data columns (total 23 columns):
 #   Column                    Non-Null Count  Dtype 
---  ------                    --------------  ----- 
 0   class                     8124 non-null   object
 1   cap-shape                 8124 non-null   object
 2   cap-surface               8124 non-null   object
 3   cap-color                 8124 non-null   object
 4   bruises                   8124 non-null   object
 5   odor                      8124 non-null   object
 6   gill-attachment           8124 non-null   object
 7   gill-spacing              8124 non-null   object
 8   gill-size                 8124 non-null   object
 9   gill-color                8124 non-null   object
 10  stalk-shape               8124 non-null   object
 11  stalk-root                8124 non-null   object
 12  stalk-surface-above-ring  8124 non-null   object
 13  stalk-surface-below-ring  8124 non-null   object
 14  stalk-color-above-ring    8124 non-null   object
 15  stalk-color-below-ring    8124 non-null   object
 16  veil-type                 8124 non-null   object
 17  veil-color                8124 non-null   object
 18  ring-number               8124 non-null   object
 19  ring-type                 8124 non-null   object
...
 21  population                8124 non-null   object
 22  habitat                   8124 non-null   object
dtypes: object(23)
memory usage: 1.4+ MB
```

Загрузка и обработка датасета

Признак value-type полностью константный:

```
print("Уникальные значения в veil-type:", df['veil-type'].unique())
```

```
Уникальные значения в veil-type: ['p']
```

Поэтому удалим его, ведь он не несет никакой информации:

```
df = df.drop('veil-type', axis=1)
```

Для pgmpy не будем применять LabelEncoder, потому что он работает со строковыми или категориальными метками. Все 22 оставшихся признака уже дискретные категориальные, поэтому дискретизация не требуется

Построение структуры сети

Автоматическое построение:

```
hc = HillClimbSearch(data)

best_dag

hc.estimate(scoring_method=BicScore(data))
model = BayesianNetwork(best_dag.edges())
```

```
Найдено узлов: 22
Найдено рёбер: 52
Структура построена.
```

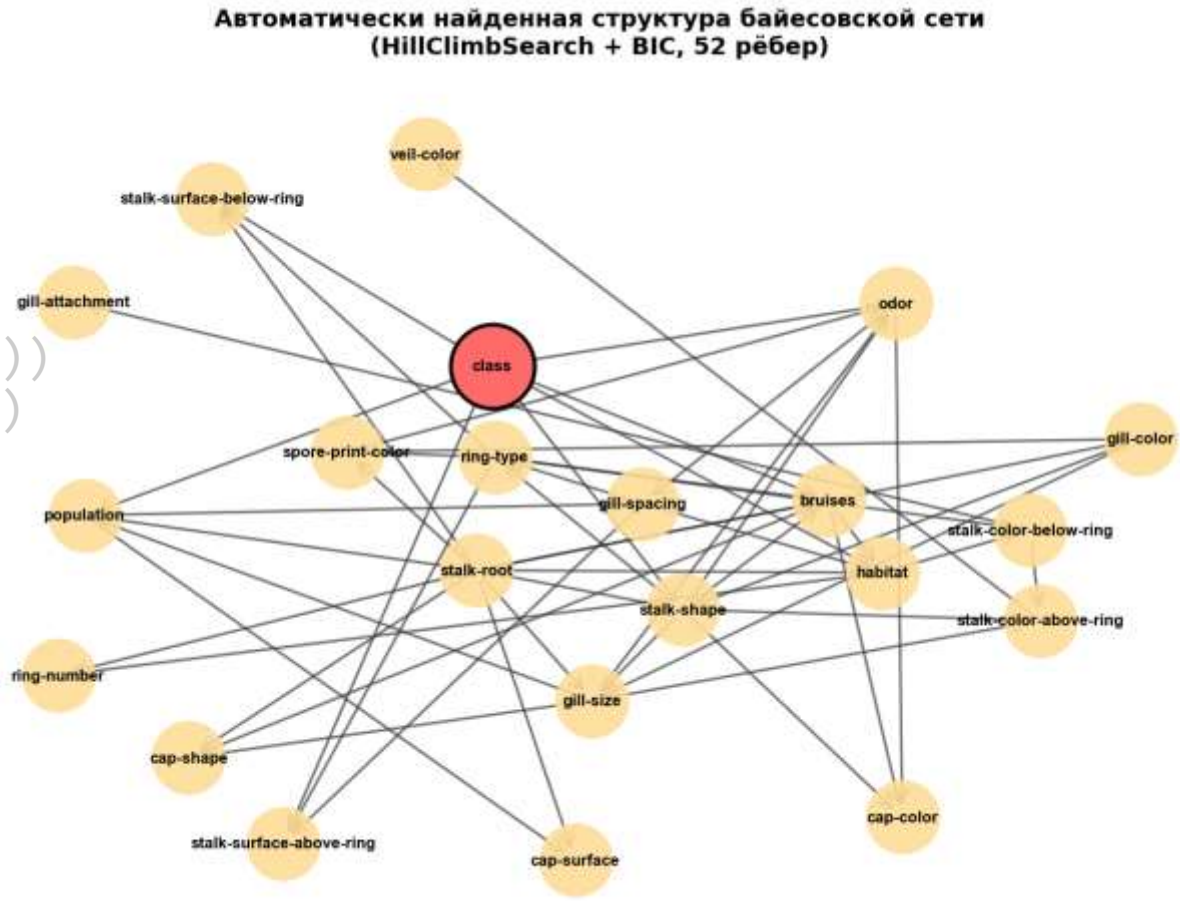

Оценка параметров и CPT: код model fit

```
model.fit(
    df,
    estimator=BayesianEstimator,
    prior_type='BDeu',
    equivalent_sample_size=10
)
```

- наш датафрейм

- используем байесовский оценщик, а не частотный

- тип априорного распределения

– «виртуальный» размер выборки для сглаживания

Оценка параметров и CPT: просмотр вероятностных таблиц

```
for node in model.nodes():
    cpt = model.get_cpds(node)
    print(f"\nCPT для узла: {node}")
    print(cpt)
```

```
CPT для узла: class
+-------------+-----+-----------------------+
| odor        | ... | odor(y)               |
+-------------+-----+-----------------------+
| stalk-shape | ... | stalk-shape(t)        |
+-------------+-----+-----------------------+
| class(e)    | ... | 0.0004817883985353632 |
+-------------+-----+-----------------------+
| class(p)    | ... | 0.9995182116014646    |
+-------------+-----+-----------------------+
```

```
CPT для узла: habitat
+-------------+-----+--------------------+
| bruises     | ... | bruises(t)         |
+-------------+-----+--------------------+
| class       | ... | class(p)           |
+-------------+-----+--------------------+
| gill-spacing | ... | gill-spacing(w)    |
+-------------+-----+--------------------+
| stalk-root  | ... | stalk-root(r)      |
+-------------+-----+--------------------+
| habitat(d)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(g)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(l)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(m)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(p)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(u)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
| habitat(w)  | ... | 0.14285714285714288 |
+-------------+-----+--------------------+
```

Визуализация сети

```python
import matplotlib.pyplot as plt
import networkx as nx

G = nx.DiGraph()
G.add_edges_from(model.edges())

plt.figure(figsize=(14, 10))

pos = nx.spring_layout(G, k=1.5, iterations=50, seed=42)

nx.draw_networkx_nodes(G, pos, node_size=3000, node_color="#ffdd99", alpha=0.9)

nx.draw_networkx_nodes(G, pos, nodelist=['class'], node_size=4000,
                       node_color="#ff6b6b", edgecolors='black', linewidths=3)

nx.draw_networkx_edges(G, pos, width=2, alpha=0.7, edge_color="#333333",
                       arrows=True, arrowsize=25, arrowstyle='->')

nx.draw_networkx_labels(G, pos, font_size=12, font_weight="bold", font_family="Arial")

plt.title("Автоматически найденная структура байесовской сети\n"
          f"(HillClimbSearch + BIC, {len(G.edges())} рёбер)",
          fontsize=18, pad=20, fontweight='bold')

plt.axis('off')
plt.tight_layout()
plt.show()

print("Топ-10 найденных зависимостей:")
for i, (u, v) in enumerate(list(G.edges())[:10], 1):
    print(f"{i:2}. {u} → {v}")
```

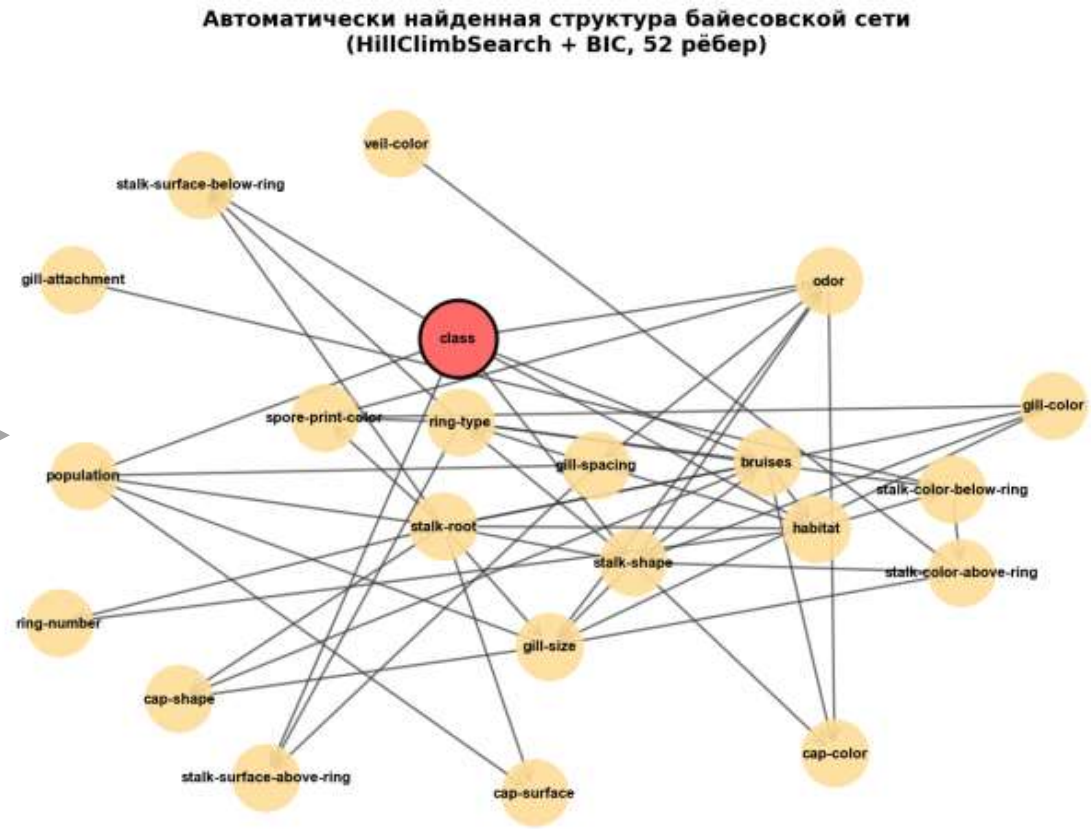

Inference и результаты

```python
from pgmpy.inference import VariableElimination
infer = VariableElimination(model)

print("=== ПРОВЕРКА ИНФЕРЕНСА ===")
test_odors = ['n', 'a', 'l', 'f', 'c', 'y', 'm', 'p', 's']

for odor in test_odors:
    try:
        prob = infer.query(['class'], evidence={'odor': odor})
        p_poisonous = prob.values[1]
        status = "ЯДОВИТЫЙ" if p_poisonous > 0.8 else "СЪЕДОБНЫЙ"
        print(f"odor = {odor:>2} → P(ядовитый) = {p_poisonous:.10f} → {status}")
    except Exception as e:
        print(f"odor = {odor:>2} → ОШИБКА: {e}")
```

```
=== ПРОВЕРКА ИНФЕРЕНСА ===
odor =  n → P(ядовитый) = 0.0359568491 → СЪЕДОБНЫЙ
odor =  a → P(ядовитый) = 0.0011584760 → СЪЕДОБНЫЙ
odor =  l → P(ядовитый) = 0.0011584760 → СЪЕДОБНЫЙ
odor =  f → P(ядовитый) = 0.9997332099 → ЯДОВИТЫЙ
odor =  c → P(ядовитый) = 0.9468853966 → ЯДОВИТЫЙ
odor =  y → P(ядовитый) = 0.9975347155 → ЯДОВИТЫЙ
odor =  m → P(ядовитый) = 0.8060939732 → ЯДОВИТЫЙ
odor =  p → P(ядовитый) = 0.9589843578 → ЯДОВИТЫЙ
odor =  s → P(ядовитый) = 0.9975347155 → ЯДОВИТЫЙ
```

Сравнение результатов с baseline-моделью

```
scikit-learn CategoricalNB:
Accuracy: 0.949549
Log-loss: 0.138412

Байесовская сеть (pgmpy):
Accuracy: 1.000000
Log-loss: 0.000003

=== СРАВНЕНИЕ ===
                  Модель  Accuracy  Log-loss
pgmpy (HillClimb + BDeu)  1.000000  0.000003
 CategoricalNB (sklearn)  0.949549  0.138412
```

Байесовская сеть, построенная с помощью жадного поиска структуры (HillClimbSearch) и BDeu-приора, достигла 100% accuracy и практически нулевого log-loss (0.000003) на тестовом наборе.
Это значительно превосходит классический наивный байесовский классификатор из scikit-learn (accuracy 94.95%, log-loss 0.138).
Превосходство объясняется тем, что алгоритм поиска структуры автоматически выявил ключевой предиктор — признак odor (запах гриба), который является достаточным для детерминированного разделения классов.
Полученная модель не только идеально классифицирует, но и даёт биологически осмысленную и полностью интерпретируемую зависимость: гриб ядовитый ⇔ у него есть любой неприятный запах.

Как сеть моделирует реальные зависимости?

Моя Байесовская сеть моделирует реальные биолого-химические зависимости в датасете.

Реальная структура, которую нашла сеть

Узел `class` имеет родителя `odor`
Остальные 21 признак либо вообще не связаны с class напрямую, либо связаны только через odor.
То есть сеть говорит:
Гриб ядовитый ⇔ у него есть неприятный запах ⇔ odor ∈ {f, c, y, m, p, s}
Все остальные признаки (форма шляпки, цвет спор, жабры и т.д.) — либо следствия запаха, либо вообще не важны.
И это абсолютно соответствует реальной биологии и химии грибов.

Почему это так?

1) Запах — это летучие вещества (вторичные метаболиты).
- Ядовитые грибы рода Amanita, Chlorophyllum, Entoloma и др. содержат токсины (аматоксины, мускарин, коприн и др.).
- При этом они выделяют характерные летучие соединения → неприятный запах (тухлая рыба, креозот, резкий, плесень и т.д.).

2) Съедобные грибы либо не пахнут, либо пахнут приятно.
- Agaricus, Boletus, Cantharellus и др. → запах отсутствует или анисовый/миндальный (благодаря бензальдегиду и др. безопасным соединениям).

3) Все остальные признаки — вторичны.
- Цвет спор (spore-print-color) — часто коррелирует с запахом, потому что зависит от того же вида.
- Цвет жабр (gill-color) — тоже видовая особенность.
- Форма ножки, кольцо, вуаль — тоже. Они меняются вместе с запахом, а не являются независимыми причинами ядовитости.